

Previsão de Energia Solar com Machine Learning

João Duarte A10361
Eduarda Ferreira A106829
Rafael Ferreira A106819




Contexto, Motivação e Objetivo

- Energia solar e transição energética
- Necessidade de previsão precisa da produção
- Competição Kaggle
- Objetivo: generalização temporal



Enquadramento em Aprendizagem Automática


- Aprendizagem supervisionada
- Tarefa de classificação
- Target qualitativo (None → Very_High)
- Métrica: accuracy (Kaggle)




Dados e Preparação



- Dados reais (energia + meteo)
- Treino: 2021–2022
- Teste: 2023 (sem labels)
- Preparação orientada ao modelo





Feedforward vs Sequências

Redes Feedforward

- Cada registo é independente
- Não existe memória
- Sem noção de ordem temporal

FeedForward = amnésico

Problema

Produção Solar

- Depende do estado recente do tempo
- Apresenta ciclo diário
- Informação distribuída no tempo



RNN, LSTM e GRU: Modelos Sequenciais

- Modelos com memória temporal
- Dependência entre instantes consecutivos
- LSTM / GRU mitigam problemas das RNN
- Adequados a sequências temporais

Para sequências relativamente curtas, como janelas de 24 horas, o aumento de complexidade nem sempre se traduziu em melhor desempenho.



Transformers: Atenção vs Complexidade

- Self-attention
- Capta dependências longas
- Elevada capacidade
- Requer tuning rigoroso

Assim, optámos por uma solução mais simples e robusta, adequada à escala e à estrutura do problema.




CNN

Hora t-23 Hora t-22 ... Hora t-1 Hora t

Janela Temporal (24 horas)

- Problema caracterizado por sequências
- Janela temporal: **24 horas**
- Periodicidade diária muito marcada
- Contexto diário explícito
- Feature Engineering temporal





Competição Kaggle

- Previsão horária de energia solar
- Classes: None → Very_High
- Dados reais (2021–2023)
- Métrica oficial: accuracy
- Mudança de distribuição temporal
- Desbalanceamento das classes
- Robustez do pipeline





Parte B: Previsão do Preço de Voos

Dataset e Variáveis

- Dataset: *Clean_Dataset.csv*
- Variáveis categóricas:
 - Companhia aérea
 - Origem / destino
 - Classe de viagem
- Variáveis numéricas:
 - Duração
 - Escalas
 - Dias de antecedência



Preparação dos Dados

- Remoção de colunas auxiliares
- Conversão de variáveis para formato numérico
- Limpeza de valores inválidos
- Conversão da duração para minutos
- Codificação por índices inteiros
- Categoria especial **UNK** para valores não vistos
- Utilização de embeddings
- Evita one-hot e alta dimensionalidade



- Embeddings para variáveis categóricas
- Inputs numéricos diretos
- Camadas densas (ReLU)
- Dropout para regularização
- Saída linear (regressão)

Embeddings + Numéricos → Concatenate → Dense → Output

Comparação de Modelos

Modelo 1 (Dropout 0.3)

- MAE $\approx$ 3094
- MSE $\approx$ 27.4M

Modelo 2 (Dropout 0.5)

- MAE $\approx$ 3193
- MSE $\approx$ 28.9M

Modelo 1 teve erros menores
Neste dataset, um nível mais elevado de Dropout levou a menor capacidade preditiva